

Hertz | 大模型算法工程师 · 模型压缩 · 多模态

LLM · PyTorch · DeepSpeed · RAG · Agent · 模型压缩

+86 138-0000-0000 | adong@example.com | 北京 · 海淀

github.com/hertz | linkedin.com/in/hertz | https://hertz.dev | https://blog.hertz.dev



计算机硕士（清华），主攻大模型方向，深耕模型压缩与微调；具备字节、腾讯大模型算法实习经验；*NeurIPS* 一作 1 篇、*Kaggle* 大模型微调金牌（*Top 1%*）、开源项目 **500+ Stars**；能独立完成数据构造 → 训练优化 → 推理部署全链路。

研究兴趣

核心方向 大语言模型压缩与加速 · 强化学习驱动的 Agent 决策 · 检索增强生成

延伸方向 多模态对齐 · 参数高效微调 · 知识蒸馏 · 长上下文建模

教育背景

清华大学 · 计算机科学与技术学院 2023.09 – 2026.06（预计）

计算机科学与技术 · 硕士 专业排名前 5%；导师方向：大语言模型

核心课程：深度学习、自然语言处理、强化学习、分布式系统、高级算法分析

荣誉：2023 国家奖学金、2024 学业优秀奖学金（一等）、优秀研究生

清华大学 · 计算机系 2019.09 – 2023.06

计算机科学与技术 · 学士 GPA 3.85/4.00；2022 春交换 ETH Zürich（成绩 5.5/6.0）

实习经历

字节跳动 · 豆包大模型团队 2024.06 – 2024.12

大模型算法实习生

主导代码与数学场景 CoT 数据构造（5B tokens 持续预训练），HumanEval/MATH/GSM8K 平均 **+5-8 pp**

设计多任务 SFT + DPO 训练（LLaMA-3-8B），50 万条多轮对话；内部 benchmark **+3 pp**，满意度 **87%**

ReAct + Tree-of-Thought 混合推理框架，工具调用准确率 **72% → 89%**，复杂任务成功率再 **+12%**

腾讯 · 微信 AI 团队 2023.06 – 2023.12

算法工程实习生

推理服务优化（KV Cache 复用 + 算子融合 + 动态批），P99 **3.2s → 1.8s**，QPS **+65%**

INT8 + 混合精度量化方案，性能保留 **98%**，显存占用 **-55%**，单机部署量翻倍

基于 vLLM 二开连续批处理 + 抢占式调度，1000+ QPS 下吞吐 **+80%**，P95 延迟 **-40%**

科研经历

清华大学 NLP 实验室 · 大模型组 2023.09 – 至今

研究助理（一作/二作）

基于强化学习的自主决策 Agent（投稿 NeurIPS 2026）：PPO + 分层 RL 框架，ALFWorld / WebShop 任务成功率 **+12-18%**，决策步数 **-25%**；MCTS+RL 混合机制使长序列样本效率 **+35%**

层级知识蒸馏与模型压缩（NeurIPS 2024 CCF-A，已发表，引 15）：注意力/隐层/输出三重对齐，LLaMA-13B → **3B**，性能保留 **95%**；MMLU/GSM8K 较 baseline **+4.2%**

论文与专利

Hierarchical Knowledge Distillation for Compact Large Language Models

Hertz, Li Si, Wang Wu

NeurIPS 2024 (CCF-A) Paper Code

Self-Reflective Agents: Reinforcement Learning for Long-Horizon Decision Making

Hertz, Zhao Liu, Chen Wei

NeurIPS 2026 (under review) Preprint Code

Retrieval-Augmented Generation with Iterative Self-Correction

Li Si, Hertz, Wang Wu

EMNLP 2024 Findings (CCF-B) Paper

发明专利 · 一种基于层级蒸馏的大模型压缩方法 2024.05

专利号 CN202410xxxx.X · 第一发明人

发明专利 · 一种支持自我反思的智能 Agent 决策方法 2024.11

专利号 CN202411xxxx.X · 第一发明人

荣誉与竞赛

Kaggle LLM Science Exam · 金牌 2023.08

Top 1% (128/2664)，方案被 Kaggle 官方教程引用

阿里云天池 LLM Fine-tuning Challenge · 全国冠军 2023.05

72 支团队，奖金 5 万；侧重小样本对齐与提示工程

清华大学国家奖学金 / 学业优秀奖学金（一等） 2023 / 2024

综合排名前 5%，连续两年

中国大学生程序设计竞赛 CCPC · 全国银奖 2022.11

东北赛区 12/380 · 队伍 ThuTeam

- 美国大学生数学建模竞赛 **MCM/ICM** • 一等奖

2021.02
- 全球 Top 8% • 建模方向: 传染病动力学预测
- GitHub 开源影响力

2023 – 至今
- 个人开源项目累计 **5,000+ Stars**, 主仓 Agent-RL-Framework 562 Stars

📁 项目经历

自我纠错型 RAG 系统 • SelfRAG-Agent 2024.01 – 2024.05

- 企业知识库 Agent, 召回率 65% → 85%, 已落地组内生产环境
- 技术栈: LangChain、LlamaIndex、Qdrant、bge-reranker、FastAPI
 - 核心方案: 迭代式检索 (ReAct 反思) + 混合检索 (向量 + BM25) + 交叉编码器重排序
 - 消融: MS MARCO / NQ 上迭代 **+15%** • 多策略融合 **+3%** • 重排序 **+2%**
- github.com/hertz/self-rag-agent rag.hertz.dev

分层记忆长程对话 Agent • HMem-Agent 2023.07 – 2023.12

- 受人类记忆机制启发, 构建工作 / 短期 / 长期三层记忆架构
- 架构: Working Memory (K 轮原文) + Short-term (自动摘要) + Long-term (重要性 + 时间衰减)
 - 效果: 信息保留率 **92%** (vs 68%), 检索 **450ms → 150ms**, 100+ 轮对话完成率 **+28%**
- github.com/hertz/hmem-agent

LLM 推理加速框架 • FastInfer 2023.03 – 2023.06

- 基于 vLLM 二次开发的低延迟推理引擎, 支持动态批处理与抢占调度
- PagedAttention 调度优化 + 自定义 CUDA Kernel + KV Cache 复用
 - A100 单卡 LLaMA-7B 吞吐 **2400 tokens/s**, 相比 baseline 提升 **1.8×**
- github.com/hertz/fastinfer

🔗 开源贡献

🔗 hertz/Agent-RL-Framework ★ 562 🍌 84 </> Python

- 强化学习驱动的 LLM Agent 决策框架 (配套 NeurIPS 投稿)
- 集成 PPO / DPO / GRPO, 覆盖 ALFWorld / WebShop / SciWorld 三基准; 处理 30+ Issues, 合并 12 PR

🔗 huggingface/transformers ★ 135k 🍌 27k </> Python

- HuggingFace 主仓库 • contributor
- 修复 Trainer.evaluate FSDP OOM (PR #28xxx); 为 Qwen2 补充长文本评测脚本

🔗 vllm-project/vllm ★ 32k 🍌 4.8k </> Python

- 高性能 LLM 推理引擎 • contributor
- PagedAttention 调度路径优化, 端到端吞吐 **+15%**; 补充 Baichuan / Yi 国产模型支持

📁 作品集

🔗 Hertz • 个人技术博客 Hexo • 累计 100k+ 阅读

- <https://blog.hertz.dev> LLM / Agent / RAG 系列原创长文 50+ 篇, 多次被「机器之心」「PaperWeekly」转载

🔗 《大模型工程化实战》技术专栏 掘金 • 25 篇 • 1.5 万关注

- <https://juejin.cn/user/hertz> 推理加速、量化部署、LangChain 实践, 单篇最高阅读 8.6 万

🔗 B 站 • LLM 论文精读频道 B 站 • 1.2 万粉丝

- <https://space.bilibili.com/hertz> 每周精读一篇顶会论文 + 可复现 Notebook, 累计播放 50 万 +

📁 专业技能

编程语言 Python (精通) • C++ / CUDA • Bash • TypeScript

大模型 **LLM** **SFT** **RLHF/DPO** LoRA/QLoRA P-Tuning Distillation Quantization RAG Agent Multimodal

框架工具 PyTorch • HuggingFace • DeepSpeed / FSDP • vLLM / TensorRT-LLM • LangChain / LlamaIndex

工程平台 Linux • Git • Docker / K8s • Ray • Slurm • W&B / MLflow • AWS / 阿里云

数据存储 PostgreSQL • Redis • Elasticsearch • Milvus / Qdrant • Kafka • Spark

语言 中文 (母语) • 英语 (CET-6, 可读写论文与技术文档)

👤 学术服务

🔗 NeurIPS 2025 审稿人 2025

- 参与 3 篇投稿论文的同行评审

🔗 ICML 2025 审稿人 2025

- 参与 2 篇投稿论文的同行评审

🔗 ACL Rolling Review 审稿人 2024 – 至今

- 累计审稿 5+ 篇

📁 教学经历

- 2025 春 | 深度学习 (研究生课程) • 清华大学 • 助教
- 负责 2 次专题讲座 (模型压缩 / 量化) + 作业批改 + 答疑

2024 秋

| 自然语言处理（本科生课程）· 清华大学 · 助教
设计并批改 3 次编程作业（RAG / LoRA / DPO）

学术交流

2025.01

| NeurIPS 2024 Poster Presentation • *Vancouver, Canada*
论文 Hierarchical Knowledge Distillation 海报展示

2024.07

| 清华大学 NLP 组组会报告 · 北京
Self-Reflective Agents: RL for Decision Making

2024.03

| 字节跳动豆包大模型技术分享 · 北京
CoT 数据构造与持续预训练实践

自我评价

- > 研究品味：以「把事做透」为准则，强调从 motivation → 实验设计 → ablation → 落地的完整闭环
- > 工程素养：能独立完成万行级训练 / 推理代码工程化，熟悉性能分析、profiling、CI 与可复现性管理
- > 协作沟通：拥有跨团队（算法 / 数据 / 工程 / 业务）协作经验，习惯撰写设计文档与公开技术分享
- > 学习能力：保持每周至少精读 1 篇顶会论文 + 复现关键实验的节奏，长期跟进 LLM / Agent / Multimodal 前沿

求职意向

- > 目标岗位：大模型算法工程师 / LLM 应用工程师 / Agent 系统研究员
- > 期望方向：模型压缩与高效推理、RAG / Agent、多模态大模型、对齐与安全
- > 期望城市：北京 / 上海 / 杭州 / Remote
- > 到岗时间：2026 年 7 月