Hertz | 大模型算法工程师 · 模型压缩 · 多模态

LLM • PyTorch • DeepSpeed • RAG • Agent • 模型压缩

+86 138-0000-0000 | adong@example.com | 北京 · 海淀
github.com/hertz | linkedin.com/in/hertz | https://hertz.dev | https://blog.hertz.dev



计算机硕士（清华），主攻大模型方向，深耕模型压缩与微调；具备字节、腾讯大模型算法实习经验；***NeurIPS*** 一作 *1* 篇、*Kaggle* 大模型微调金牌（*Top 1%*）、开源项目 ***500+ Stars***；能独立完成数据构造 → 训练优化 → 推理部署全链路。

研究兴趣

核心方向 大语言模型压缩与加速 • 强化学习驱动的 Agent 决策 • 检索增强生成

延伸方向 多模态对齐 • 参数高效微调 • 知识蒸馏 • 长上下文建模

教育背景

清华大学 • 计算机科学与技术学院 2023.09 – 2026.06（预计）

计算机科学与技术 • 硕士　专业排名前 5%；导师方向：大语言模型

- **核心课程**：深度学习、自然语言处理、强化学习、分布式系统、高级算法分析
- **荣誉**：2023 国家奖学金、2024 学业优秀奖学金（一等）、优秀研究生

清华大学 • 计算机系 2019.09 – 2023.06

计算机科学与技术 • 学士　GPA 3.85/4.00；2022 春交换 ETH Zürich（成绩 5.5/6.0）

实习经历

字节跳动 • 豆包大模型团队 2024.06 – 2024.12

大模型算法实习生

- 主导代码与数学场景 CoT 数据构造（5B tokens 持续预训练），HumanEval/MATH/GSM8K 平均 **+5–8 pp**
- 设计多任务 SFT + DPO 训练（LLaMA-3-8B），50 万条多轮对话；内部 benchmark **+3 pp**，满意度 **87%**
- ReAct + Tree-of-Thought 混合推理框架，工具调用准确率 **72% → 89%**，复杂任务成功率再 **+12%**

腾讯 • 微信 AI 团队 2023.06 – 2023.12

算法工程实习生

- 推理服务优化（KV Cache 复用 + 算子融合 + 动态批），P99 **3.2s → 1.8s**，QPS **+65%**
- INT8 + 混合精度量化方案，性能保留 **98%**，显存占用 **−55%**，单机部署量翻倍
- 基于 vLLM 二开连续批处理 + 抢占式调度，1000+ QPS 下吞吐 **+80%**，P95 延迟 **−40%**

科研经历

清华大学 NLP 实验室 • 大模型组 2023.09 – 至今

研究助理（一作 / 二作）

- **基于强化学习的自主决策 Agent**（投稿 NeurIPS 2026）：PPO + 分层 RL 框架，ALFWorld / WebShop 任务成功率 **+12–18%**，决策步数 **−25%**；MCTS+RL 混合机制使长序列样本效率 **+35%**
- **层级知识蒸馏与模型压缩**（NeurIPS 2024 CCF-A，已发表，引 15）：注意力/隐层/输出三重对齐，LLaMA-13B → **3B**，性能保留 **95%**；MMLU/GSM8K 较 baseline **+4.2%**

论文与专利

Hierarchical Knowledge Distillation for Compact Large Language Models

Hertz, Li Si, Wang Wu

NeurIPS 2024 (CCF-A)　Paper　Code

Self-Reflective Agents: Reinforcement Learning for Long-Horizon Decision Making

Hertz, Zhao Liu, Chen Wei

NeurIPS 2026 (under review)　Preprint　Code

Retrieval-Augmented Generation with Iterative Self-Correction

Li Si, **Hertz**, Wang Wu

EMNLP 2024 Findings (CCF-B)　Paper

发明专利 • 一种基于层级蒸馏的大模型压缩方法 2024.05
专利号 CN202410xxxxx.X • 第一发明人

发明专利 • 一种支持自我反思的智能 Agent 决策方法 2024.11
专利号 CN202411xxxxx.X • 第一发明人

荣誉与竞赛

Kaggle LLM Science Exam • 金牌 2023.08
Top 1%（128/2664），方案被 Kaggle 官方教程引用

阿里云天池 LLM Fine-tuning Challenge • 全国冠军 2023.05
72 支团队，奖金 5 万；侧重小样本对齐与提示工程

清华大学国家奖学金 / 学业优秀奖学金（一等） 2023 / 2024
综合排名前 5%，连续两年

中国大学生程序设计竞赛 CCPC • 全国银奖 2022.11
东北赛区 12/380 • 队伍 ThuTeam

美国大学生数学建模竞赛 MCM/ICM • 一等奖 2021.02
全球 Top 8% • 建模方向：传染病动力学预测

GitHub 开源影响力 2023 – 至今
个人开源项目累计 **5,000+ Stars**，主仓 Agent-RL-Framework 562 Stars

项目经历

自我纠错型 RAG 系统 • SelfRAG-Agent 2024.01 – 2024.05
企业知识库 Agent，召回率 65% → 85%，已落地组内生产环境

- **技术栈**：LangChain、LlamaIndex、Qdrant、bge-reranker、FastAPI
- **核心方案**：迭代式检索（ReAct 反思）+ 混合检索（向量 + BM25）+ 交叉编码器重排序
- **消融**：MS MARCO / NQ 上迭代 **+15%** • 多策略融合 **+3%** • 重排序 **+2%**

hertz/self-rag-agent rag.hertz.dev

分层记忆长程对话 Agent • HMem-Agent 2023.07 – 2023.12
受人类记忆机制启发，构建工作 / 短期 / 长期三层记忆架构

- **架构**：Working Memory（K 轮原文）+ Short-term（自动摘要）+ Long-term（重要性 + 时间衰减）
- **效果**：信息保留率 **92%**（vs 68%），检索 **450ms → 150ms**，100+ 轮对话完成率 **+28%**

hertz/hmem-agent

LLM 推理加速框架 • FastInfer 2023.03 – 2023.06
基于 vLLM 二次开发的低延迟推理引擎，支持动态批处理与抢占调度

- PagedAttention 调度优化 + 自定义 CUDA Kernel + KV Cache 复用
- A100 单卡 LLaMA-7B 吞吐 **2400 tokens/s**，相比 baseline 提升 **1.8×**

hertz/fastinfer

开源贡献

hertz/Agent-RL-Framework ★ 562 ⑂ 84 </> Python
强化学习驱动的 LLM Agent 决策框架（配套 NeurIPS 投稿）

- 集成 PPO / DPO / GRPO，覆盖 ALFWorld / WebShop / SciWorld 三基准；处理 30+ Issues，合并 12 PR

huggingface/transformers ★ 135k ⑂ 27k </> Python
HuggingFace 主仓库 • contributor

- 修复 Trainer.evaluate FSDP OOM（PR #28xxx）；为 Qwen2 补充长文本评测脚本

vllm-project/vllm ★ 32k ⑂ 4.8k </> Python

高性能 *LLM* 推理引擎 • *contributor*

- PagedAttention 调度路径优化，端到端吞吐 **+15%**；补充 Baichuan / Yi 国产模型支持

作品集

Hertz • 个人技术博客 Hexo • 累计 100k+ 阅读
https://blog.hertz.dev LLM / Agent / RAG 系列原创长文 50+ 篇，多次被「机器之心」「PaperWeekly」转载

《大模型工程化实战》技术专栏 掘金 • 25 篇 • 1.5 万关注
https://juejin.cn/user/hertz 推理加速、量化部署、LangChain 实践，单篇最高阅读 8.6 万

B 站 • LLM 论文精读频道 B 站 • 1.2 万粉丝
https://space.bilibili.com/hertz 每周精读一篇顶会论文 + 可复现 Notebook，累计播放 50 万 +

专业技能

编程语言	Python（精通）• C++ / CUDA • Bash • TypeScript
大模型	**LLM** **SFT** **RLHF/DPO** LoRA/QLoRA P-Tuning Distillation Quantization RAG Agent Multimodal
框架工具	PyTorch • HuggingFace • DeepSpeed / FSDP • vLLM / TensorRT-LLM • LangChain / LlamaIndex
工程平台	Linux • Git • Docker / K8s • Ray • Slurm • W&B / MLflow • AWS / 阿里云
数据存储	PostgreSQL • Redis • Elasticsearch • Milvus / Qdrant • Kafka • Spark
语言	中文（母语）• 英语（CET-6，可读写论文与技术文档）

学术服务

NeurIPS 2025 审稿人 2025
参与 3 篇投稿论文的同行评审

ICML 2025 审稿人 2025
参与 2 篇投稿论文的同行评审

ACL Rolling Review 审稿人 2024 – 至今
累计审稿 5+ 篇

教学经历

2025 春 **深度学习（研究生课程）** • 清华大学 · 助教
负责 2 次专题讲座（模型压缩 / 量化）+ 作业批改 + 答疑

2024 秋 **自然语言处理（本科生课程）** • 清华大学 · 助教
设计并批改 3 次编程作业（RAG / LoRA / DPO）

学术交流

2025.01 **NeurIPS 2024 Poster Presentation** • *Vancouver, Canada*
论文 Hierarchical Knowledge Distillation 海报展示

2024.07 **清华大学 NLP 组组会报告** • 北京
Self-Reflective Agents: RL for Decision Making

2024.03 **字节跳动豆包大模型技术分享** • 北京
CoT 数据构造与持续预训练实践

自我评价

- **研究品味**：以「把事做透」为准则，强调从 motivation → 实验设计 → ablation → 落地的完整闭环
- **工程素养**：能独立完成万行级训练 / 推理代码工程化，熟悉性能分析、profiling、CI 与可复现性管理
- **协作沟通**：拥有跨团队（算法 / 数据 / 工程 / 业务）协作经验，习惯撰写设计文档与公开技术分享
- **学习能力**：保持每周至少精读 1 篇顶会论文 + 复现关键实验的节奏，长期跟进 LLM / Agent / Multimodal 前沿

求职意向

- **目标岗位**：大模型算法工程师 / LLM 应用工程师 / Agent 系统研究员

- **期望方向**：模型压缩与高效推理、RAG / Agent、多模态大模型、对齐与安全
- **期望城市**：北京 / 上海 / 杭州 / Remote
- **到岗时间**：2026 年 7 月