

Hertz | 大模型算法工程师 · 模型压缩 · 多模态

LLM · PyTorch · DeepSpeed · RAG · Agent · 模型压缩

+86 138-0000-0000 | adong@example.com | 北京 · 海淀

github.com/hertz | linkedin.com/in/hertz | https://hertz.dev | https://blog.hertz.dev



计算机硕士（清华），主攻大模型方向，深耕模型压缩与微调；具备字节、腾讯大模型算法实习经验；*NeurIPS* 一作 1 篇、*Kaggle* 大模型微调金牌（*Top 1%*）、开源项目 **500+ Stars**；能独立完成数据构造 → 训练优化 → 推理部署全链路。

专业技能

编程语言 Python（精通）· C++ / CUDA · Bash · TypeScript

大模型 **LLM** **SFT** **RLHF/DPO** LoRA/QLoRA P-Tuning Distillation Quantization RAG Agent Multimodal

框架工具 PyTorch · HuggingFace · DeepSpeed / FSDP · vLLM / TensorRT-LLM · LangChain / LlamaIndex

工程平台 Linux · Git · Docker / K8s · Ray · Slurm · W&B / MLflow · AWS / 阿里云

数据存储 PostgreSQL · Redis · Elasticsearch · Milvus / Qdrant · Kafka · Spark

语言 中文（母语）· 英语（CET-6，可读写论文与技术文档）

教育背景

清华大学 · 计算机科学与技术学院 2023.09 – 2026.06（预计）
计算机科学与技术 · 硕士 专业排名前 5%；导师方向：大语言模型

▸ 核心课程：深度学习、自然语言处理、强化学习、分布式系统、高级算法分析

▸ 荣誉：2023 国家奖学金、2024 学业优秀奖学金（一等）、优秀研究生

清华大学 · 计算机系 2019.09 – 2023.06
计算机科学与技术 · 学士 GPA 3.85/4.00；2022 春交换 ETH Zürich（成绩 5.5/6.0）

实习经历

字节跳动 · 豆包大模型团队 2024.06 – 2024.12
大模型算法实习生

- 主导代码与数学场景 CoT 数据构造（5B tokens 持续预训练），HumanEval/MATH/GSM8K 平均 **+5–8 pp**
- 设计多任务 SFT + DPO 训练（LLaMA-3-8B），50 万条多轮对话；内部 benchmark **+3 pp**，满意度 **87%**
- ReAct + Tree-of-Thought 混合推理框架，工具调用准确率 **72% → 89%**，复杂任务成功率再 **+12%**

腾讯 · 微信 AI 团队 2023.06 – 2023.12
算法工程实习生

- 推理服务优化（KV Cache 复用 + 算子融合 + 动态批），P99 **3.2s → 1.8s**，QPS **+65%**
- INT8 + 混合精度量化方案，性能保留 **98%**，显存占用 **-55%**，单机部署量翻倍
- 基于 vLLM 二开连续批处理 + 抢占式调度，1000+ QPS 下吞吐 **+80%**，P95 延迟 **-40%**

科研经历

清华大学 NLP 实验室 · 大模型组 2023.09 – 至今
研究助理（一作/二作）

- 基于强化学习的自主决策 **Agent**（投稿 NeurIPS 2026）：PPO + 分层 RL 框架，ALFWorld / WebShop 任务成功率 **+12–18%**，决策步数 **-25%**；MCTS+RL 混合机制使长序列样本效率 **+35%**
- 层级知识蒸馏与模型压缩（NeurIPS 2024 CCF-A，已发表，引 15）：注意力/隐层/输出三重对齐，LLaMA-13B → **3B**，性能保留 **95%**；MMLU/GSM8K 较 baseline **+4.2%**

论文与专利

Hierarchical Knowledge Distillation for Compact Large Language Models

Hertz, Li Si, Wang Wu
NeurIPS 2024 (CCF-A) Paper Code

Self-Reflective Agents: Reinforcement Learning for Long-Horizon Decision Making

Hertz, Zhao Liu, Chen Wei
NeurIPS 2026 (under review) Preprint Code

Retrieval-Augmented Generation with Iterative Self-Correction

Li Si, Hertz, Wang Wu
EMNLP 2024 Findings (CCF-B) Paper

发明专利 · 一种基于层级蒸馏的大模型压缩方法 2024.05
专利号 CN202410xxxx.X · 第一发明人

发明专利 · 一种支持自我反思的智能 Agent 决策方法 2024.11
专利号 CN202411xxxx.X · 第一发明人

荣誉与竞赛

Kaggle LLM Science Exam · 金牌 2023.08
Top 1% (128/2664)，方案被 Kaggle 官方教程引用

阿里云天池 LLM Fine-tuning Challenge · 全国冠军 2023.05
72 支团队，奖金 5 万；侧重小样本对齐与提示工程

🏆 清华大学国家奖学金 / 学业优秀奖学金（一等） 综合排名前 5%，连续两年	2023 / 2024
🏆 中国大学生程序设计竞赛 CCPC • 全国银奖 东北赛区 12/380 • 队伍 ThuTeam	2022.11
🏆 美国大学生数学建模竞赛 MCM/ICM • 一等奖 全球 Top 8% • 建模方向：传染病动力学预测	2021.02
🏆 GitHub 开源影响力 个人开源项目累计 5,000+ Stars ，主仓 Agent-RL-Framework 562 Stars	2023 – 至今

📁 项目经历

自我纠错型 RAG 系统 • SelfRAG-Agent 2024.01 – 2024.05

企业知识库 Agent，召回率 65% → 85%，已落地组内生产环境

- 技术栈：LangChain、LlamaIndex、Qdrant、bge-reranker、FastAPI
- 核心方案：迭代式检索（ReAct 反思）+ 混合检索（向量 + BM25）+ 交叉编码器重排序
- 消融：MS MARCO / NQ 上迭代 **+15%** • 多策略融合 **+3%** • 重排序 **+2%**

🔗 github.com/hertz/self-rag-agent 🌐 rag.hertz.dev

分层记忆长程对话 Agent • HMem-Agent 2023.07 – 2023.12

受人类记忆机制启发，构建工作 / 短期 / 长期三层记忆架构

- 架构：Working Memory（K 轮原文）+ Short-term（自动摘要）+ Long-term（重要性 + 时间衰减）
- 效果：信息保留率 **92%**（vs 68%），检索 **450ms → 150ms**，100+ 轮对话完成率 **+28%**

🔗 github.com/hertz/hmem-agent

LLM 推理加速框架 • FastInfer 2023.03 – 2023.06

基于 vLLM 二次开发的低延迟推理引擎，支持动态批处理与抢占调度

- PagedAttention 调度优化 + 自定义 CUDA Kernel + KV Cache 复用
- A100 单卡 LLaMA-7B 吞吐 **2400 tokens/s**，相比 baseline 提升 **1.8×**

🔗 github.com/hertz/fastinfer

🔗 开源贡献

🔗 hertz/Agent-RL-Framework ★ 562 📄 84 📄 Python

强化学习驱动的 LLM Agent 决策框架（配套 NeurIPS 投稿）

- 集成 PPO / DPO / GRPO，覆盖 ALFWorld / WebShop / SciWorld 三基准；处理 30+ Issues，合并 12 PR

🔗 huggingface/transformers ★ 135k 📄 27k 📄 Python

HuggingFace 主仓库 • contributor

- 修复 Trainer.evaluate FSDP OOM（PR #28xxx）；为 Qwen2 补充长文本评测脚本

🔗 vllm-project/vllm ★ 32k 📄 4.8k 📄 Python

高性能 LLM 推理引擎 • contributor

- PagedAttention 调度路径优化，端到端吞吐 **+15%**；补充 Baichuan / Yi 国产模型支持

📁 作品集

🔗 Hertz • 个人技术博客 Hexo • 累计 100k+ 阅读

🔗 <https://blog.hertz.dev> LLM / Agent / RAG 系列原创长文 50+ 篇，多次被「机器之心」「PaperWeekly」转载

🔗 《大模型工程化实战》技术专栏 掘金 • 25 篇 • 1.5 万关注

🔗 <https://juejin.cn/user/hertz> 推理加速、量化部署、LangChain 实践，单篇最高阅读 8.6 万

🔗 B 站 • LLM 论文精读频道 B 站 • 1.2 万粉丝

🔗 <https://space.bilibili.com/hertz> 每周精读一篇顶会论文 + 可复现 Notebook，累计播放 50 万 +