Hertz | 大模型算法工程师 · 模型压缩 · 多模态

LLM • PyTorch • DeepSpeed • RAG • Agent • 模型压缩

+86 138-0000-0000 | adong@example.com | 北京 · 海淀
github.com/hertz | linkedin.com/in/hertz | https://hertz.dev | https://blog.hertz.dev

专业技能

编程 Python • C++ / CUDA • Bash

大模型 **LLM** **SFT** **RLHF/DPO** LoRA RAG Agent Quantization

框架 PyTorch • DeepSpeed • vLLM • LangChain • Docker / K8s

教育背景

清华大学 • 计算机系 2023.09 – 2026.06

计算机科学与技术 • 硕士　排名前 5% • 国家奖学金

清华大学 • 计算机系 2019.09 – 2023.06

计算机科学与技术 • 学士　GPA 3.85/4.00 • ETH 交换

实习经历

字节跳动 • 豆包大模型团队 2024.06 – 2024.12

大模型算法实习生

- CoT 数据构造 5B tokens 持续预训练，HumanEval/MATH 平均 **+5–8 pp**
- 多任务 SFT + DPO（LLaMA-3-8B），满意度 **87%**，benchmark **+3 pp**
- ReAct + ToT 混合推理框架，工具调用 **72% → 89%**

腾讯 • 微信 AI 团队 2023.06 – 2023.12

算法工程实习生

- 推理服务优化，P99 **3.2s → 1.8s**，QPS **+65%**
- INT8 量化方案，性能保留 **98%**，显存 **−55%**

项目经历

自我纠错型 RAG 系统 2024.01 – 2024.05

企业知识库 *Agent*，召回率 *65% → 85%*

- 迭代式检索 + 混合检索 + 交叉编码器重排序，MS MARCO **+15%**

github.com/hertz/self-rag-agent

LLM 推理加速框架 • FastInfer 2023.03 – 2023.06

基于 *vLLM* 二开的低延迟推理引擎

- PagedAttention + KV Cache 复用，A100 吞吐 **2400 tok/s**，提升 **1.8×**

github.com/hertz/fastinfer

代表性成果

NeurIPS 2024 一作（CCF-A） 层级知识蒸馏

Kaggle LLM 金牌 Top 1% 2023

开源 5000+ Stars Agent-RL-Framework