



专业技能

编程 Python · C++ / CUDA · Bash

大模型 LLM SFT RLHF/DPO LoRA RAG Agent Quantization

框架 PyTorch · DeepSpeed · vLLM · LangChain · Docker / K8s

教育背景

- 清华大学 · 计算机系

2023.09 – 2026.06

计算机科学与技术 · 硕士 排名前 5% · 国家奖学金
- 清华大学 · 计算机系

2019.09 – 2023.06

计算机科学与技术 · 学士 GPA 3.85/4.00 · ETH 交换

实习经历

- 字节跳动 · 豆包大模型团队

2024.06 – 2024.12

大模型算法实习生
 - CoT 数据构造 5B tokens 持续预训练, HumanEval/MATH 平均 **+5–8 pp**
 - 多任务 SFT + DPO (LLaMA-3-8B), 满意度 **87%**, benchmark **+3 pp**
 - ReAct + ToT 混合推理框架, 工具调用 **72% → 89%**
- 腾讯 · 微信 AI 团队

2023.06 – 2023.12

算法工程实习生
 - 推理服务优化, P99 **3.2s → 1.8s**, QPS **+65%**
 - INT8 量化方案, 性能保留 **98%**, 显存 **-55%**

项目经历

- 自我纠错型 RAG 系统

2024.01 – 2024.05

企业知识库 Agent, 召回率 **65% → 85%**
 - 迭代式检索 + 混合检索 + 交叉编码器重排序, MS MARCO **+15%**

github.com/hertz/self-rag-agent
- LLM 推理加速框架 · FastInfer

2023.03 – 2023.06

基于 vLLM 二开的低延迟推理引擎
 - PagedAttention + KV Cache 复用, A100 吞吐 **2400 tok/s**, 提升 **1.8x**

github.com/hertz/fastinfer

代表性成果

- NeurIPS 2024 一作 (CCF-A)

层级知识蒸馏
- Kaggle LLM 金牌 Top 1%

2023
- 开源 5000+ Stars

Agent-RL-Framework