



专业技能

编程 Python · C++ / CUDA · Bash

大模型 LLM SFT RLHF/DPO LoRA RAG Agent Quantization

框架 PyTorch · DeepSpeed · vLLM · LangChain · Docker / K8s

教育背景

清华大学 · 计算机系	2023.09 – 2026.06
计算机科学与技术 · 硕士	排名前 5% · 国家奖学金
清华大学 · 计算机系	2019.09 – 2023.06
计算机科学与技术 · 学士	GPA 3.85/4.00 · ETH 交换

实习经历

字节跳动 · 豆包大模型团队	2024.06 – 2024.12
大模型算法实习生	
CoT 数据构造 5B tokens 持续预训练, HumanEval/MATH 平均 +5-8 pp	
多任务 SFT + DPO (LLaMA-3-8B), 满意度 87%, benchmark +3 pp	
ReAct + ToT 混合推理框架, 工具调用 72% → 89%	
腾讯 · 微信 AI 团队	2023.06 – 2023.12
算法工程实习生	
推理服务优化, P99 3.2s → 1.8s, QPS +65%	
INT8 量化方案, 性能保留 98%, 显存 -55%	

项目经历

自我纠错型 RAG 系统	2024.01 – 2024.05
企业知识库 Agent, 召回率 65% → 85%	
迭代式检索 + 混合检索 + 交叉编码器重排序, MS MARCO +15%	
github.com/hertz/self-rag-agent	
LLM 推理加速框架 · FastInfer	2023.03 – 2023.06
基于 vLLM 二开的低延迟推理引擎	
PagedAttention + KV Cache 复用, A100 吞吐 2400 tok/s, 提升 1.8x	
github.com/hertz/fastinfer	

代表性成果

NeurIPS 2024 一作 (CCF-A)	层级知识蒸馏
Kaggle LLM 金牌 Top 1%	2023
开源 5000+ Stars	Agent-RL-Framework