



计算机硕士 (清华), 主攻大模型方向, 深耕模型压缩与微调; 具备字节、腾讯大模型算法实习经验; **NeurIPS** 一作 1 篇、**Kaggle** 大模型微调金牌 (**Top 1%**)、开源项目 **500+ Stars**; 能独立完成数据构造 → 训练优化 → 推理部署全链路。

专业技能

编程语言 Python (精通) · C++ / CUDA · Bash · TypeScript

大模型 **LLM** **SFT** **RLHF/DPO** **LoRA/QLoRA** **P-Tuning** **Distillation** **Quantization** **RAG** **Agent** **Multimodal**

框架工具 PyTorch · HuggingFace · DeepSpeed / FSDP · vLLM / TensorRT-LLM · LangChain / LlamaIndex

工程平台 Linux · Git · Docker / K8s · Ray · Slurm · W&B / MLflow · AWS / 阿里云

数据存储 PostgreSQL · Redis · Elasticsearch · Milvus / Qdrant · Kafka · Spark

语言 中文 (母语) · 英语 (CET-6, 可读写论文与技术文档)

实习经历

字节跳动 · 豆包大模型团队

2024.06 – 2024.12

大模型算法实习生

- 主导代码与数学场景 CoT 数据构造 (5B tokens 持续预训练), HumanEval/MATH/GSM8K 平均 **+5–8 pp**
- 设计多任务 SFT + DPO 训练 (LLaMA-3-8B), 50 万条多轮对话; 内部 benchmark **+3 pp**, 满意度 **87%**
- ReAct + Tree-of-Thought 混合推理框架, 工具调用准确率 **72% → 89%**, 复杂任务成功率再 **+12%**

腾讯 · 微信 AI 团队

2023.06 – 2023.12

算法工程实习生

- 推理服务优化 (KV Cache 复用 + 算子融合 + 动态批), P99 **3.2s → 1.8s**, QPS **+65%**
- INT8 + 混合精度量化方案, 性能保留 **98%**, 显存占用 **-55%**, 单机部署量翻倍
- 基于 vLLM 二开连续批处理 + 抢占式调度, 1000+ QPS 下吞吐 **+80%**, P95 延迟 **-40%**

科研经历

清华大学 NLP 实验室 · 大模型组

2023.09 – 至今

研究助理 (一作 / 二作)

- 基于强化学习的自主决策 **Agent** (投稿 NeurIPS 2026): PPO + 分层 RL 框架, ALFWorld / WebShop 任务成功率 **+12–18%**, 决策步数 **-25%**; MCTS+RL 混合机制使长序列样本效率 **+35%**
- 层级知识蒸馏与模型压缩 (NeurIPS 2024 CCF-A, 已发表, 引 15): 注意力/隐层/输出三重对齐, LLaMA-13B → **3B**, 性能保留 **95%**; MMLU/GSM8K 较 baseline **+4.2%**

项目经历

自我纠错型 RAG 系统 · SelfRAG-Agent

2024.01 – 2024.05

企业知识库 **Agent**, 召回率 **65% → 85%**, 已落地组内生产环境

- 技术栈: LangChain、LlamaIndex、Qdrant、bge-reranker、FastAPI
- 核心方案: 迭代式检索 (ReAct 反思) + 混合检索 (向量 + BM25) + 交叉编码器重排序
- 消融: MS MARCO / NQ 上迭代 **+15%** · 多策略融合 **+3%** · 重排序 **+2%**

hertz/self-rag-agent | rag.hertz.dev

分层记忆长程对话 Agent · HMem-Agent

2023.07 – 2023.12

受人类记忆机制启发, 构建工作 / 短期 / 长期三层记忆架构

- 架构: Working Memory (K 轮原文) + Short-term (自动摘要) + Long-term (重要性 + 时间衰减)
- 效果: 信息保留率 **92%** (vs 68%), 检索 **450ms → 150ms**, 100+ 轮对话完成率 **+28%**

hertz/hmem-agent

LLM 推理加速框架 · FastInfer

2023.03 – 2023.06

基于 vLLM 二次开发的低延迟推理引擎, 支持动态批处理与抢占调度

- PagedAttention 调度优化 + 自定义 CUDA Kernel + KV Cache 复用
- A100 单卡 LLaMA-7B 吞吐 **2400 tokens/s**, 相比 baseline 提升 **1.8x**

hertz/fastinfer

开源贡献

-  **hertz/Agent-RL-Framework** ★ 562 🔗 84 🔗 Python

强化学习驱动的 LLM Agent 决策框架 (配套 NeurIPS 投稿)

集成 PPO / DPO / GRPO, 覆盖 ALFWorld / WebShop / SciWorld 三基准; 处理 30+ Issues, 合并 12 PR
-  **huggingface/transformers** ★ 135k 🔗 27k 🔗 Python

HuggingFace 主仓库 · contributor

修复 Trainer.evaluate FSDP OOM (PR #28xxx); 为 Qwen2 补充长文本评测脚本
-  **vllm-project/vllm** ★ 32k 🔗 4.8k 🔗 Python

高性能 LLM 推理引擎 · contributor

PagedAttention 调度路径优化, 端到端吞吐 +15%; 补充 Baichuan / Yi 国产模型支持

作品集

-  **Hertz · 个人技术博客** Hexo · 累计 100k+ 阅读

<https://blog.hertz.dev> LLM / Agent / RAG 系列原创长文 50+ 篇, 多次被「机器之心」「PaperWeekly」转载
-  **《大模型工程化实战》技术专栏** 掘金 · 25 篇 · 1.5 万关注

<https://juejin.cn/user/hertz> 推理加速、量化部署、LangChain 实践, 单篇最高阅读 8.6 万
-  **B 站 · LLM 论文精读频道** B 站 · 1.2 万粉丝

<https://space.bilibili.com/hertz> 每周精读一篇顶会论文 + 可复现 Notebook, 累计播放 50 万 +

教育背景

-  **清华大学 · 计算机科学与技术学院** 2023.09 – 2026.06 (预计)

计算机科学与技术 · 硕士 专业排名前 5%; 导师方向: 大语言模型

核心课程: 深度学习、自然语言处理、强化学习、分布式系统、高级算法分析

荣誉: 2023 国家奖学金、2024 学业优秀奖学金 (一等)、优秀研究生
-  **清华大学 · 计算机系** 2019.09 – 2023.06

计算机科学与技术 · 学士 GPA 3.85/4.00; 2022 春交换 ETH Zürich (成绩 5.5/6.0)

论文与专利

- Hierarchical Knowledge Distillation for Compact Large Language Models**

Hertz, Li Si, Wang Wu

NeurIPS 2024 (CCF-A)  Paper  Code
- Self-Reflective Agents: Reinforcement Learning for Long-Horizon Decision Making**

Hertz, Zhao Liu, Chen Wei

NeurIPS 2026 (under review)  Preprint  Code
- Retrieval-Augmented Generation with Iterative Self-Correction**

Li Si, Hertz, Wang Wu

EMNLP 2024 Findings (CCF-B)  Paper
-  **发明专利 · 一种基于层级蒸馏的大模型压缩方法** 2024.05

专利号 CN202410xxxxx.X · 第一发明人
-  **发明专利 · 一种支持自我反思的智能 Agent 决策方法** 2024.11

专利号 CN202411xxxxx.X · 第一发明人

荣誉与竞赛

-  **Kaggle LLM Science Exam · 金牌** 2023.08

Top 1% (128/2664), 方案被 Kaggle 官方教程引用
-  **阿里云天池 LLM Fine-tuning Challenge · 全国冠军** 2023.05

72 支团队, 奖金 5 万; 侧重小样本对齐与提示工程
-  **清华大学国家奖学金 / 学业优秀奖学金 (一等)** 2023 / 2024

综合排名前 5%, 连续两年
-  **中国大学生程序设计竞赛 CCPC · 全国银奖** 2022.11

东北赛区 12/380 · 队伍 ThuTeam

- 

美国大学生数学建模竞赛 **MCM/ICM** • 一等奖

全球 Top 8% • 建模方向: 传染病动力学预测

2021.02
- 

GitHub 开源影响力

个人开源项目累计 **5,000+ Stars**, 主仓 Agent-RL-Framework 562 Stars

2023 – 至今