

Hertz | 大模型算法工程师 · 模型压缩 · 多模态

LLM · PyTorch · DeepSpeed · RAG · Agent · 模型压缩

+86 138-0000-0000 | adong@example.com | 北京 · 海淀

github.com/hertz | linkedin.com/in/hertz | https://hertz.dev | https://blog.hertz.dev



计算机硕士（清华），主攻大模型方向，深耕模型压缩与微调；具备字节、腾讯大模型算法实习经验；*NeurIPS* 一作 1 篇、*Kaggle* 大模型微调金牌（*Top 1%*）、开源项目 **500+ Stars**；能独立完成数据构造 → 训练优化 → 推理部署全链路。

专业技能

编程语言 Python（精通）· C++ / CUDA · Bash · TypeScript

大模型

LLM SFT RLHF/DPO LoRA/QLoRA P-Tuning Distillation Quantization RAG Agent Multimodal

框架工具

PyTorch · HuggingFace · DeepSpeed / FSDP · vLLM / TensorRT-LLM · LangChain / LlamaIndex

工程平台

Linux · Git · Docker / K8s · Ray · Slurm · W&B / MLflow · AWS / 阿里云

数据存储

PostgreSQL · Redis · Elasticsearch · Milvus / Qdrant · Kafka · Spark

语言

中文（母语）· 英语（CET-6，可读写论文与技术文档）

项目经历

自我纠错型 RAG 系统 · SelfRAG-Agent

2024.01 – 2024.05

企业知识库 Agent，召回率 65% → 85%，已落地组内生产环境

- 技术栈：LangChain、LlamaIndex、Qdrant、bge-reranker、FastAPI
- 核心方案：迭代式检索（ReAct 反思）+ 混合检索（向量 + BM25）+ 交叉编码器重排序
- 消融：MS MARCO / NQ 上迭代 +15% · 多策略融合 +3% · 重排序 +2%

github.com/hertz/self-rag-agent rag.hertz.dev

分层记忆长程对话 Agent · HMem-Agent

2023.07 – 2023.12

受人类记忆机制启发，构建工作/短期/长期三层记忆架构

- 架构：Working Memory（K 轮原文）+ Short-term（自动摘要）+ Long-term（重要性 + 时间衰减）
- 效果：信息保留率 92%（vs 68%），检索 450ms → 150ms，100+ 轮对话完成率 +28%

github.com/hertz/hmem-agent

LLM 推理加速框架 · FastInfer

2023.03 – 2023.06

基于 vLLM 二次开发的低延迟推理引擎，支持动态批处理与抢占调度

- PagedAttention 调度优化 + 自定义 CUDA Kernel + KV Cache 复用
- A100 单卡 LLaMA-7B 吞吐 2400 tokens/s，相比 baseline 提升 1.8×

github.com/hertz/fastinfer

开源贡献

hertz/Agent-RL-Framework

★ 562 🍴 84 🔄 Python

强化学习驱动的 LLM Agent 决策框架（配套 *NeurIPS* 投稿）

- 集成 PPO / DPO / GRPO，覆盖 ALFWorld / WebShop / SciWorld 三基准；处理 30+ Issues，合并 12 PR

huggingface/transformers

★ 135k 🍴 27k 🔄 Python

HuggingFace 主仓库 · contributor

- 修复 Trainer.evaluate FSDP OOM（PR #28xxx）；为 Qwen2 补充长文本评测脚本

vllm-project/vllm

★ 32k 🍴 4.8k 🔄 Python

高性能 LLM 推理引擎 · contributor

- PagedAttention 调度路径优化，端到端吞吐 +15%；补充 Baichuan / Yi 国产模型支持

作品集

Hertz · 个人技术博客

Hexo · 累计 100k+ 阅读

https://blog.hertz.dev LLM / Agent / RAG 系列原创长文 50+ 篇，多次被「机器之心」「PaperWeekly」转载

《大模型工程化实战》技术专栏

掘金 · 25 篇 · 1.5 万关注

https://juejin.cn/user/hertz 推理加速、量化部署、LangChain 实践，单篇最高阅读 8.6 万

B 站 · LLM 论文精读频道

B 站 · 1.2 万粉丝

https://space.bilibili.com/hertz 每周精读一篇顶会论文 + 可复现 Notebook，累计播放 50 万 +

实习经历

字节跳动 · 豆包大模型团队

2024.06 – 2024.12

大模型算法实习生

- 主导代码与数学场景 CoT 数据构造（5B tokens 持续预训练），HumanEval/MATH/GSM8K 平均 +5–8 pp
- 设计多任务 SFT + DPO 训练（LLaMA-3-8B），50 万条多轮对话；内部 benchmark +3 pp，满意度 87%
- ReAct + Tree-of-Thought 混合推理框架，工具调用准确率 72% → 89%，复杂任务成功率再 +12%

T	腾讯 · 微信 AI 团队	2023.06 – 2023.12
	算法工程实习生	
	➢ 推理服务优化 (KV Cache 复用 + 算子融合 + 动态批), P99 3.2s → 1.8s , QPS +65%	
	➢ INT8 + 混合精度量化方案, 性能保留 98% , 显存占用 -55% , 单机部署量翻倍	
🔬	基于 vLLM 二开连续批处理 + 抢占式调度, 1000+ QPS 下吞吐 +80% , P95 延迟 -40%	
	科研经历	
	清华大学 NLP 实验室 · 大模型组	2023.09 – 至今
	研究助理 (一作/二作)	
□□	➢ 基于强化学习的自主决策 Agent (投稿 NeurIPS 2026): PPO + 分层 RL 框架, ALFWorld / WebShop 任务成功率 +12–18% , 决策步数 -25% ; MCTS+RL 混合机制使长序列样本效率 +35%	
	➢ 层级知识蒸馏与模型压缩 (NeurIPS 2024 CCF-A, 已发表, 引 15): 注意力/隐层/输出三重对齐, LLaMA-13B → 3B , 性能保留 95% ; MMLU/GSM8K 较 baseline +4.2%	
	教育背景	
	清华大学 · 计算机科学与技术学院	2023.09 – 2026.06 (预计)
□□	计算机科学与技术 · 硕士	专业排名前 5%; 导师方向: 大语言模型
	➢ 核心课程: 深度学习、自然语言处理、强化学习、分布式系统、高级算法分析	
	➢ 荣誉: 2023 国家奖学金、2024 学业优秀奖学金 (一等)、优秀研究生	
	清华大学 · 计算机系	2019.09 – 2023.06
□□	计算机科学与技术 · 学士	GPA 3.85/4.00; 2022 春交换 ETH Zürich (成绩 5.5/6.0)
	论文与专利	
	Hierarchical Knowledge Distillation for Compact Large Language Models	
	Hertz, Li Si, Wang Wu	
	NeurIPS 2024 (CCF-A) 📄 Paper 🔄 Code	
	Self-Reflective Agents: Reinforcement Learning for Long-Horizon Decision Making	
	Hertz, Zhao Liu, Chen Wei	
	NeurIPS 2026 (under review) 📄 Preprint 🔄 Code	
	Retrieval-Augmented Generation with Iterative Self-Correction	
	Li Si, Hertz, Wang Wu	
	EMNLP 2024 Findings (CCF-B) 📄 Paper	
	发明专利 · 一种基于层级蒸馏的大模型压缩方法	2024.05
	专利号 CN202410xxxxx.X · 第一发明人	
	发明专利 · 一种支持自我反思的智能 Agent 决策方法	2024.11
	专利号 CN202411xxxxx.X · 第一发明人	
	荣誉与竞赛	
🏆	Kaggle LLM Science Exam · 金牌	2023.08
	Top 1% (128/2664), 方案被 Kaggle 官方教程引用	
	阿里云天池 LLM Fine-tuning Challenge · 全国冠军	2023.05
	72 支团队, 奖金 5 万; 侧重小样本对齐与提示工程	
🏆	清华大学国家奖学金 / 学业优秀奖学金 (一等)	2023 / 2024
	综合排名前 5%, 连续两年	
	中国大学生程序设计竞赛 CCPC · 全国银奖	2022.11
	东北赛区 12/380 · 队伍 ThuTeam	
🏆	美国大学生数学建模竞赛 MCM/ICM · 一等奖	2021.02
	全球 Top 8% · 建模方向: 传染病动力学预测	
	GitHub 开源影响力	2023 – 至今
	个人开源项目累计 5,000+ Stars , 主仓 Agent-RL-Framework 562 Stars	