

Hertz

大模型算法工程师 · 模型压缩 · 多模态

联系方式

+86 138-0000-0000
hertz@example.com
北京 · 海淀
github.com/hertz
linkedin.com/in/hertz
hertz.dev

核心技能

语言

Python · C++ / CUDA · Bash

大模型

LLM RLHF
LoRA Distill Quant
RAG Agent

框架

PyTorch · DeepSpeed · vLLM · LangChain

语言能力

中文 ●●●●●
英文 ●●●●○

荣誉

- Kaggle LLM 金牌 (Top 1%)
- 天池 LLM 微调全国冠军
- 清华国家奖学金
- MCM/ICM 一等奖
- GitHub 5000+ Stars

计算机硕士在读，主攻大模型方向，深耕模型压缩与微调；具备字节、腾讯大模型算法实习经验；***NeurIPS*** 一作 *1* 篇、*Kaggle* 大模型微调金牌（*Top 1%*）、开源 ***500+ Stars***。

教育背景

清华大学 2023.09 – 2026.06
计算机科学与技术 • 硕士　排名前 5%

清华大学 2019.09 – 2023.06
计算机科学与技术 • 学士　GPA 3.85/4.00

实习经历

字节跳动 • 豆包 LLM 团队 2024.06 – 2024.12
LLM 算法实习生

- CoT 数据 5B tokens 持续预训练，HumanEval/MATH 平均 **+5–8 pp**
- 多任务 SFT + DPO（LLaMA-3-8B），用户满意度 **87%**
- ReAct + ToT 混合推理，工具调用 **72% → 89%**

腾讯 • 微信 AI 2023.06 – 2023.12
算法实习生

- 推理服务优化，P99 **3.2s → 1.8s**，QPS **+65%**
- INT8 量化方案，性能保留 **98%**，显存 **−55%**
- vLLM 二开连续批处理，1000+ QPS 吞吐 **+80%**

项目精选

自我纠错 RAG • `SelfRAG-Agent` 2024.01–05
召回率 65% → 85%，已落地组内生产

- 迭代检索 + 混合检索 + 交叉编码器 rerank
- MS MARCO / NQ 上累计 **+20%** 提升

github.com/hertz/self-rag-agent

论文

Hierarchical Knowledge Distillation for Compact LLMs
Hertz, Li Si, Wang Wu
NeurIPS 2024 (CCF-A)　Paper