



Hertz

大模型算法工程师 · 模型压缩 · 多模态

联系方式

+86 138-0000-0000
hertz@example.com
北京 · 海淀
github.com/hertz
linkedin.com/in/hertz
hertz.dev

核心技能

语言
Python · C++ / CUDA · Bash
大模型
LLM RLHF
LoRA Distill Quant
RAG Agent
框架
PyTorch · DeepSpeed · vLLM · LangChain

语言能力

中文 ●●●●●
英文 ●●●●●

荣誉

- Kaggle LLM 金牌 (Top 1%)
- 天池 LLM 微调全国冠军
- 清华国家奖学金
- MCM/ICM 一等奖
- GitHub 5000+ Stars

计算机硕士在读，主攻大模型方向，深耕模型压缩与微调；具备字节、腾讯大模型算法实习经验；*NeurIPS* 一作 1 篇、*Kaggle* 大模型微调金牌 (Top 1%)、开源 **500+ Stars**。

教育背景

清华大学 2023.09 – 2026.06
计算机科学与技术 · 硕士 排名前 5%
清华大学 2019.09 – 2023.06
计算机科学与技术 · 学士 GPA 3.85/4.00

实习经历

字节跳动 · 豆包 LLM 团队 2024.06 – 2024.12
LLM 算法实习生
CoT 数据 5B tokens 持续预训练，HumanEval/MATH 平均 **+5-8 pp**
多任务 SFT + DPO (LLaMA-3-8B)，用户满意度 **87%**
ReAct + ToT 混合推理，工具调用 **72% → 89%**
腾讯 · 微信 AI 2023.06 – 2023.12
算法实习生
推理服务优化，P99 **3.2s → 1.8s**，QPS **+65%**
INT8 量化方案，性能保留 **98%**，显存 **-55%**
vLLM 二开连续批处理，1000+ QPS 吞吐 **+80%**

项目精选

自我纠错 RAG · SelfRAG-Agent 2024.01-05
召回率 65% → 85%，已落地组内生产
迭代检索 + 混合检索 + 交叉编码器 rerank
MS MARCO / NQ 上累计 **+20%** 提升
github.com/hertz/self-rag-agent

论文

Hierarchical Knowledge Distillation for Compact LLMs
Hertz, Li Si, Wang Wu
NeurIPS 2024 (CCF-A) Paper