



Hertz

大模型算法工程师 · 模型压缩 · 多模态

联系方式

+86 138-0000-0000

hertz@example.com

北京 · 海淀

github.com/hertz

linkedin.com/in/hertz

hertz.dev

核心技能

语言

Python · C++ / CUDA · Bash

大模型

LLM RLHF

LoRA Distill Quant

RAG Agent

框架

PyTorch · DeepSpeed · vLLM · LangChain

语言能力

中文 ●●●●●

英文 ●●●●●

荣誉

- Kaggle LLM 金牌 (Top 1%)
- 天池 LLM 微调全国冠军
- 清华国家奖学金
- MCM/ICM 一等奖
- GitHub 5000+ Stars

计算机硕士在读，主攻大模型方向，深耕模型压缩与微调；具备字节、腾讯大模型算法实习经验；**NeurIPS** 一作 1 篇、**Kaggle** 大模型微调金牌 (Top 1%)、开源 **500+ Stars**。

教育背景

清华大学	2023.09 – 2026.06
计算机科学与技术 · 硕士	排名前 5%
清华大学	2019.09 – 2023.06
计算机科学与技术 · 学士	GPA 3.85/4.00

实习经历

字节跳动 · 豆包 LLM 团队	2024.06 – 2024.12
LLM 算法实习生	
CoT 数据 5B tokens 持续预训练, HumanEval/MATH 平均 +5–8 pp	
多任务 SFT + DPO (LLaMA-3-8B), 用户满意度 87%	
ReAct + ToT 混合推理, 工具调用 72% → 89%	
腾讯 · 微信 AI	2023.06 – 2023.12
算法实习生	
推理服务优化, P99 3.2s → 1.8s, QPS +65%	
INT8 量化方案, 性能保留 98%, 显存 -55%	
vLLM 二开连续批处理, 1000+ QPS 吞吐 +80%	

项目精选

自我纠错 RAG • SelfRAG-Agent	2024.01–05
召回率 65% → 85%, 已落地组内生产	
迭代检索 + 混合检索 + 交叉编码器 rerank	
MS MARCO / NQ 上累计 +20% 提升	
github.com/hertz/self-rag-agent	

论文

Hierarchical Knowledge Distillation for Compact LLMs	
Hertz, Li Si, Wang Wu	
NeurIPS 2024 (CCF-A)	Paper